张三

zhangsan_dev@gmail.com
福建厦门 2001.02 123-4567-8910（微信同号）

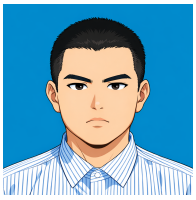

教育背景

厦门大学（985，本科） 软件工程（专业前 10%，**推免**至本校） **2019.09 ~ 2023.06**

厦门大学（985，硕士） 电子信息（研究方向：**多智能体协同与 RAG 架构**） **2023.09 ~ 2026.06**

- **学术成果**：英语六级 573 分；以第一作者在 **ACL 2024**、**AAAI 2023** 各发表文章一篇。
- **荣誉奖项**：国家奖学金 (2020、2024)、厦大一等奖学金 (2021、2025)、中国研究生 AI 创新大赛一等奖。

实习经历

北京 ABC 科技有限公司 大模型算法实习生 **2025.05 ~ 2025.08**

项目介绍：负责自研千亿级 LLM 在垂直领域的逻辑进化，通过全链路偏好对齐提升模型的诊断推理能力。

1）**对齐训练（核心）：**基于 **TRL** 深度优化 **DPO** 对齐管线，引入 **Iterative DPO** 策略实现多轮策略博弈；通过动态调整 **KL 散度系数**严控策略漂移，并设计 **Reward Model**，解决模型幻觉问题，增强回复的深度；同时针对医疗场景复杂长尾问题，结合 **Rejection Sampling** 机制对高质量回答进行过滤与二次微调，显著提升了模型在临床推理中的鲁棒性。

2）**数据工程：**利用 **Tagging** 过滤千万级原始语料，结合 **Self-Instruct** 策略合成高质量医疗指令数据。

3）**推理部署：**主导 **vLLM** 生产环境部署，利用 **Prefix Caching** 与 **PD 分离**策略优化 **TTFT**，提升吞吐效率。

项目成果：医疗逻辑评测得分提升 **22%**，幻觉率降低 **18%**，单卡吞吐较 Baseline 提升 **2.8 倍**。

上海一二三技术有限公司 AI 算法工程师实习生 **2024.09 ~ 2024.12**

项目介绍：开发基于智能体协作的医疗决策平台，实现临床数据的自动化检索、逻辑规划与多维分析。

1）**RAG 优化：**基于 **Milvus** 构建 Hybrid Search 系统，引入 **BGE-Reranker** 解决医疗术语召回不精准问题；采用 **BM25** 结合稠密向量检索的双路召回机制，并针对长篇电子病历与医学指南设计了**语义感知切分（Semantic Chunking）**策略，大幅降低了由于上下文截断导致的深层语义丢失风险。

2）**Agent 开发（核心）：**利用 **LangGraph** 编排复杂的 **ReAct** 模式工作流，构建具备“规划-反思-执行”闭环的 **Multi-Agent** 体系；设计针对多源数据的逻辑路由，实现知识库及临床工具的高精度自动化调用。

3）**模型微调：**采用 **PEFT（QLoRA）**实施指令增强，引入 **FlashAttention-2** 保证模型的推理稳定性。

项目成果：RAG 检索准确率提升至 **91%**，Agent 任务成功率达 **94%**，成功支撑 3 家三甲医院私有化部署。

项目经历

Medical-Llama：开源中文医疗大模型 项目负责人 **2023.02 ~ 2023.08**

项目介绍：通过领域增强预训练与指令微调，构建高性能医疗垂直领域大模型。

1）**全流程管线构建：**自建从 **增量预训练**到 **SFT** 再到 **DPO** 的完整链路，主导千万级高质量医疗数据清洗；并设计基于启发式规则与大模型打分的双重过滤机制，有效剔除了低质量语料与隐私敏感数据。

2）**高效微调策略：**应用 **PEFT（LoRA）**技术实现高效迭代，引入 **FlashAttention-2** 优化长文本处理性能。

3）**临床能力对齐：**针对医学严谨性与伦理准则，构建海量高质量医疗偏好对（**Preference Pairs**），利用 **DPO** 算法实施细粒度偏好对齐，通过动态调整差异惩罚项（**KL Penalty**）优化模型输出分布。

项目成果：核心算法论文发表于 **AAAI 2023 (1st Author)**；项目在 **GitHub** 获 6.2k+ Stars。

X-Agent：医疗多模态 Agent 决策系统 核心开发 **2024.01 ~ 2024.06**

项目介绍：基于智能体架构，整合医疗知识库与临床工具，实现端到端的自动化辅助诊断与多维数据分析。

1）**工作流编排：**利用 **LangGraph** 设计复杂的 **ReAct** 模式工作流；通过构建“主诊智能体”提出方案与“知识校验智能体”基于临床路径进行多轮博弈与共识生成机制，解决了复杂链路的逻辑断层与幻觉问题。

2）**系统解耦与工具集成：**通过 **Dify** 实现业务逻辑高度解耦，集成外部医学计算器与自研 RAG 引擎；同时封装标准化 API 接口以支持多终端快速接入，大幅降低了系统的二次开发成本与各模块间的耦合度。

3）**工程化部署：**利用 **vLLM** 部署模型后端，结合 **Docker** 容器化技术完成私有化环境交付，优化响应延迟。

项目成果：研究成果发表于 **ACL 2024 (1st Author)**；项目在 **GitHub** 获 2.8k+ Stars。

专业素养

- **技术栈：PyTorch，Transformers，vLLM，DeepSpeed，TRL（DPO/PPO），PEFT，LoRA**，LangChain，LangGraph，Dify，Milvus，FAISS，Docker，Linux，Git，Python，C++。
- **自我评价：**具备出色的逻辑思维与问题解决能力，能高效阅读并转化顶会前沿论文；工作自驱力强，能够在高压力环境下保持高效产出，具有良好的团队协作精神与沟通效率。